



我把有关联的序列一起分到同一组

先连接 exact、source cluster、legacy component 与 MMseqs2 关系，再按整个 component 切分。

a row-wise split 会把“亲戚”分到两边



b 冻结数据上的泄漏审计



同样的 60/20/20 比例




图 2 | Cluster-aware split。审计阈值为 MMseqs2 identity $\geq 30\%$ 、双向 coverage $\geq 80\%$ ；0 条残留边不证明更远同源完全不存在。